UTS

PEMBELAJARAN MESIN



NAMA : Muh. Raihan Huda Negara

NIM : 202531075

KELAS : H

DOSEN : Rizqia Cahyaningtyas, ST., M.Kom

NO.PC : 13

ASISTEN : 1. Muhammad Ichwan Fauzi

2. Benedict Samuel Ardy

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

BAB I PENDAHULUAN 1
1.1 Rumusan Masalah 1
1.2 Tujuan Masalah 1
1.3 Manfaat Masalah 1
BAB II LANDASAN TEORI 2
2.1 Pembelajaran Terawasi dan Data Bank 2
2.2 EDA dan Persiapan Data 2
2.3 Regresi Linear 3
2.4 Naive Bayes 4
2.5 Evaluasi Klasifikasi 4
BAB III HASIL 5
3.1 Persiapan dan Pemeriksaan Dataset 5
3.2 Eksplorasi dan Pembagian Data 9
3.3 Regresi Linear 13
3.4 Naive Bayes 18
3.5 Pembahasan Hasil dan Keterbatasan 24
BAB IV PENUTUP 25
4.1 Kesimpulan 25
4.2 Saran 25
DAFTAR PUSTAKA 26

BAB I

PENDAHULUAN

1.1 Rumusan Masalah

Penulis mengolah dataset 4, yaitu 04_bank_customers.csv, melalui dua tugas pembelajaran mesin. Regresi Linear memperkirakan saldo rata-rata tahunan pada kolom balance, sedangkan Naive Bayes memperkirakan status berlangganan deposito pada kolom y. Kedua tugas memakai data latih dan data uji yang sama, dengan target serta ukuran evaluasi yang berbeda. Penelitian Chian dkk. [1] memberi konteks penggunaan klasifikasi untuk pemasaran langsung bank.

Pemilihan target y mengikuti isi dataset: setiap catatan memiliki label yes atau no tentang langganan deposito. Untuk tugas regresi, penulis memilih balance karena nilainya berupa angka. Saldo pada kolom tersebut berbeda dari gaji; praktikum ini tidak memakai data penghasilan nasabah. Penulis merumuskan masalah berikut.

1. Bagaimana kondisi dataset berdasarkan struktur kolom, nilai kosong, kategori unknown, duplikasi, distribusi saldo, dan proporsi respons deposito?

2. Bagaimana menyiapkan fitur dan membagi data untuk melatih Regresi Linear serta Naive Bayes?

3. Seberapa tepat prediksi saldo dan klasifikasi deposito pada data uji, serta kesalahan apa yang masih muncul?

1.2 Tujuan Masalah

Penulis memeriksa karakteristik dataset, menyiapkan fitur untuk masing-masing algoritma, dan membagi data menjadi 80% data latih serta 20% data uji. Setelah pelatihan, penulis menilai galat prediksi saldo dan kemampuan klasifikasi dalam mengenali kelas yes maupun no.

1.3 Manfaat Masalah

Melalui praktikum ini, penulis mempelajari perbedaan regresi dan klasifikasi serta cara membaca metrik evaluasi. Dokumentasi dalam Jupyter Notebook memungkinkan pembaca menelusuri kode, keluaran, dan dasar kesimpulan. Analisis ini juga melatih penulis membedakan keberhasilan menjalankan program dari ketepatan model saat memprediksi data yang tidak ikut dalam pelatihan.

BAB II

LANDASAN TEORI

2.1 Pembelajaran Terawasi dan Data Bank

Dalam pembelajaran terawasi, peneliti memberikan pasangan atribut masukan dan jawaban yang telah tersedia. Atribut menjelaskan keadaan suatu pengamatan, sedangkan target menjadi nilai yang hendak diperkirakan. Peneliti memakai regresi untuk target angka dan klasifikasi untuk target kategori. Dalam praktikum ini, satu kumpulan data mendukung dua percobaan terpisah: perkiraan balance dan klasifikasi y.

Chian dkk. [1] membahas klasifikasi keberhasilan pemasaran langsung bank. Penulis memakai artikel tersebut sebagai konteks penerapan, bukan sebagai hasil percobaan. Izma dan Firmansyah [6] juga mengkaji respons deposito dan melaporkan kesulitan mengenali kelas berlangganan. Perbedaan pemilihan fitur, pengolahan, dan pembagian data dapat menghasilkan kinerja yang berbeda meskipun peneliti membahas topik serupa.

2.2 EDA dan Persiapan Data

Melalui exploratory data analysis atau EDA, peneliti memeriksa tipe kolom, kelengkapan, duplikasi, statistik, serta sebaran data. Pemeriksaan ini membantu peneliti memilih pengolahan yang sesuai. Nilai unknown menunjukkan informasi yang tidak diketahui, sedangkan nilai kosong standar biasanya ditandai NaN. Peneliti perlu membedakan kedua bentuk tersebut sebelum menghapus baris atau mengisi nilai.

Pemisahan data latih dan data uji memberi kesempatan untuk menilai prediksi pada pengamatan yang tidak ikut melatih model. Stratifikasi mempertahankan proporsi kelas pada kedua bagian. Kapoor dan Narayanan [4] menjelaskan bahwa kebocoran informasi dapat menyebabkan penilaian kinerja terlalu tinggi. Karena itu, peneliti mempelajari batas interval dan daftar kategori dari data latih, lalu menerapkan aturan yang sama pada data uji.

Pada kode praktikum, penulis menjalankan EDA pada seluruh data sebelum pembagian. Penulis kemudian mempelajari transformasi Naive Bayes dari data latih saja. Nilai unknown dan pdays = -1 tetap dipertahankan; penulis tidak melakukan imputasi. Untuk fitur nominal pada regresi, penulis membentuk variabel dummy. Untuk Categorical Naive Bayes, penulis memakai kode kategori nonnegatif.

2.3 Regresi Linear

Regresi Linear memperkirakan target sebagai kombinasi linear atribut masukan. Peneliti memakai regresi berganda saat menyediakan beberapa prediktor untuk satu target. Roustaei [2] menjelaskan penggunaan variabel dummy, penafsiran koefisien, dan pemeriksaan asumsi regresi. Bentuk umum model berganda adalah:

$$\hat{y}_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$$

Simbol $\hat{y}$ menyatakan prediksi, β_0 intersep, β_j koefisien, dan p jumlah prediktor. Melalui ordinary least squares, peneliti mencari koefisien yang meminimalkan jumlah kuadrat selisih nilai aktual dan prediksi. Untuk prediktor nominal, variabel dummy bernilai 0 atau 1 menandai kategori. Satu kategori menjadi acuan agar peneliti dapat menafsirkan perbedaan antarkategori.

Penulis menggunakan balance sebagai target numerik dan mengeluarkannya dari masukan. Penulis juga mengeluarkan y serta duration, sehingga tersisa 14 atribut asal. Hubungan prediktif dalam data observasional tidak membuktikan bahwa perubahan pekerjaan atau status perkawinan menyebabkan perubahan saldo. Penulis menilai hasil regresi dengan galat pada data uji:

$$\mathrm{MAE} = \frac{\Sigma\,|y_i - \hat{y}_i|}{n}$$

$$\mathrm{RMSE} = \sqrt{\frac{\Sigma\,(y_i - \hat{y}_i)^2}{n}}$$

$$R^2 = 1 - \frac{\Sigma\,(y_i - \hat{y}_i)^2}{\Sigma\,(y_i - \bar{y}_{uji})^2}$$

MAE menunjukkan rata-rata besar kesalahan, sedangkan RMSE memberi bobot lebih besar pada kesalahan ekstrem. Keduanya memakai satuan target. Pada R^2, penulis membandingkan jumlah galat kuadrat dengan penyimpangan saldo dari rata-rata data uji. Nilai 1 berarti prediksi tepat; nilai mendekati 0 menunjukkan sedikit perbaikan terhadap acuan rata-rata, dan nilai negatif menunjukkan hasil lebih buruk. R^2 bukan persentase prediksi yang benar.

Penulis memeriksa grafik aktual terhadap prediksi dan residual, yaitu saldo aktual dikurangi prediksi. Pola kesalahan berulang atau sebaran yang melebar memberi alasan untuk meninjau pendekatan linear [2].

2.4 Naive Bayes

Naive Bayes menggunakan teorema Bayes dengan asumsi independensi atribut secara kondisional setelah kelas diketahui. Gohari dkk. [3] membahas asumsi tersebut dalam pengembangan model untuk data medis. Penulis memakai landasan teoretisnya; implementasi praktikum adalah CategoricalNB.

$$P(C_k \mid x) \propto P(C_k) \prod_j P(x_j \mid C_k)$$

Prior menyatakan proporsi kelas dan likelihood menyatakan peluang kategori atribut di dalam kelas. Pada pelatihan, algoritma menghitung frekuensi kategori per kelas. Pada prediksi, algoritma memilih kelas dengan skor posterior terbesar. Penghalusan Laplace dengan $\alpha = 1$ menghindari peluang nol untuk kategori yang belum muncul dalam suatu kelas.

Pada Categorical Naive Bayes, penulis menyiapkan masukan sebagai kode kategori. Penulis membagi age dan balance menjadi lima interval kuantil dari data latih. Untuk 13 kolom lain, penulis memberi kode pada tiap nilai berbeda, termasuk nilai diskret day, campaign, pdays, dan previous. Kode pekerjaan menandai jenis pekerjaan, tanpa menyatakan urutan tingkat pekerjaan. Jawaban target tetap berbentuk teks yes dan no.

2.5 Evaluasi Klasifikasi

Chicco dan Jurman [5] menyarankan pembacaan beberapa ukuran evaluasi yang saling melengkapi. Dengan yes sebagai kelas positif, TP berarti yes yang diprediksi yes; TN berarti no yang diprediksi no; FP berarti no yang diprediksi yes; dan FN berarti yes yang diprediksi no.

$$\text{Akurasi} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP} \quad ; \quad \text{Recall} = \frac{TP}{TP + FN}$$

$$F_1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

Akurasi menilai seluruh prediksi. Precision yes menilai ketepatan prediksi yes, sedangkan recall yes menilai bagian dari seluruh pelanggan berlangganan yang dikenali. F1 menggabungkan keduanya. Pada data yang didominasi no, penulis membaca confusion matrix bersama metrik per kelas agar akurasi tidak menutupi banyaknya yes yang terlewat.

BAB III

HASIL

3.1 Persiapan dan Pemeriksaan Dataset

Penulis menjalankan 21 sel dalam Jupyter Notebook. Urutannya meliputi pemeriksaan data, eksplorasi, pembagian data, Regresi Linear, dan Naive Bayes. Kedua model mempelajari target yang berbeda dan tidak saling meneruskan hasil prediksi. Gambar pada bab ini memuat kode serta keluaran praktikum.

Sel 1 Memuat pustaka

```
# NIM: 202531075

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from zipfile import ZipFile

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import OrdinalEncoder, KBinsDiscretizer
from sklearn.linear_model import LinearRegression
from sklearn.naive_bayes import CategoricalNB
from sklearn.metrics import (
    mean_absolute_error,
    mean_squared_error,
    r2_score,
    accuracy_score,
    classification_report,
    ConfusionMatrixDisplay
)
```

Gambar 3.1 Pustaka yang digunakan dalam praktikum

Penulis memuat NumPy untuk perhitungan dan penggabungan array, pandas untuk mengolah tabel, serta Matplotlib untuk menampilkan grafik. Dari scikit-learn, penulis mengambil pembagian data, pengolahan kategori, dua algoritma, dan fungsi evaluasi. Komentar NIM memberi identitas pada sel tanpa memengaruhi perhitungan.

Sel ini belum melatih model dan tidak menghasilkan keluaran khusus. Import ZipFile masih tercantum pada screenshot, tetapi sel berikutnya membaca CSV langsung sehingga pustaka tersebut tidak dipakai. Penulis tidak membuat fungsi penyimpanan grafik; seluruh grafik tampil di notebook.

Sel 2 Membaca dataset

```
# NIM: 202531075

df = pd.read_csv("04_bank_customers.csv", sep=";")

df.head()
```

Gambar 3.2a Pembacaan CSV dengan pemisah titik koma

	age	job	marital	education	default	balance
0	58	management	married	tertiary	no	2143
1	44	technician	single	secondary	no	29
2	33	entrepreneur	married	secondary	no	2
3	47	blue-collar	married	unknown	no	1506
4	33	unknown	single	unknown	no	1

Gambar 3.2b Kolom profil dan saldo pada lima baris pertama

housing	loan	contact	day	month	duration	campaign	pdays	previous	poutcome	y
yes	no	unknown	5	may	261	1	-1	0	unknown	no
yes	no	unknown	5	may	151	1	-1	0	unknown	no
yes	yes	unknown	5	may	76	1	-1	0	unknown	no
yes	no	unknown	5	may	92	1	-1	0	unknown	no
no	no	unknown	5	may	198	1	-1	0	unknown	no

Gambar 3.2c Kelanjutan kolom pada lima baris yang sama

Penulis membaca 04_bank_customers.csv memakai pd.read_csv dengan sep=";" karena berkas memakai titik koma sebagai pemisah. CSV berada dalam folder yang sama dengan notebook. Melalui df.head(), penulis menampilkan lima baris pertama untuk memeriksa apakah kolom terbaca terpisah.

Kolom balance menyatakan saldo rata-rata tahunan dalam euro, sedangkan y menyatakan status langganan deposito. Kolom y menjadi target klasifikasi; balance menjadi target regresi. Contoh pada lima baris pertama belum mewakili proporsi seluruh respons, sehingga penulis menghitung distribusi kelas pada sel 7.

Sel 3 Memeriksa struktur data

```
# NIM: 202531075

df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 45211 entries, 0 to 45210
Data columns (total 17 columns):
 #   Column     Non-Null Count  Dtype
---  ------     --------------  -----
 0   age        45211 non-null  int64
 1   job        45211 non-null  str
 2   marital    45211 non-null  str
 3   education  45211 non-null  str
 4   default    45211 non-null  str
 5   balance    45211 non-null  int64
 6   housing    45211 non-null  str
 7   loan       45211 non-null  str
 8   contact    45211 non-null  str
 9   day        45211 non-null  int64
 10  month      45211 non-null  str
 11  duration   45211 non-null  int64
 12  campaign   45211 non-null  int64
 13  pdays      45211 non-null  int64
 14  previous   45211 non-null  int64
 15  poutcome   45211 non-null  str
 16  y          45211 non-null  str
dtypes: int64(7), str(10)
memory usage: 5.9 MB
```

Gambar 3.3 Struktur dan tipe kolom dataset

Melalui df.info(), penulis memperoleh 45.211 baris dan 17 kolom. Tujuh kolom bertipe int64 dan sepuluh kolom bertipe teks. Setiap kolom memiliki 45.211 nilai non-null, sehingga pemeriksaan ini tidak menemukan nilai kosong standar.

Informasi non-null belum menjelaskan kelengkapan isi secara keseluruhan. Teks unknown tetap terhitung sebagai nilai yang terisi. Karena itu, penulis memeriksa unknown secara terpisah pada sel berikutnya. Campuran angka dan teks juga menjadi dasar pemilihan cara pengolahan fitur untuk masing-masing algoritma.

Sel 4 Memeriksa nilai kosong dan unknown

```
# NIM: 202531075

pd.DataFrame({
    "kosong": df.isna().sum(),
    "unknown": (df == "unknown").sum()
})
```

Gambar 3.4a Pemeriksaan nilai kosong standar dan unknown

	kosong	unknown
age	0	0
job	0	288
marital	0	0
education	0	1857
default	0	0
balance	0	0
housing	0	0
loan	0	0
contact	0	13020
day	0	0
month	0	0
duration	0	0
campaign	0	0
pdays	0	0
previous	0	0
poutcome	0	36959
y	0	0

Gambar 3.4b Hasil pemeriksaan kolom awal dan kelanjutannya

Penulis memakai isna().sum() untuk menghitung nilai kosong dan perbandingan terhadap teks unknown untuk menghitung informasi yang tidak diketahui. Seluruh kolom memiliki nol nilai kosong standar. Unknown muncul pada job sebanyak 288, education 1.857, contact 13.020, dan poutcome 36.959. Penulis mempertahankannya sebagai kategori tersendiri.

Sel 5 Memeriksa duplikasi

```
# NIM: 202531075

df.duplicated().sum()
```

```
np.int64(0)
```

Gambar 3.5 Hasil pemeriksaan baris duplikat

Fungsi duplicated().sum() menghasilkan 0. Penulis tidak menemukan baris yang identik pada seluruh kolom, sehingga tidak menghapus duplikasi. Hasil ini tidak memastikan identitas nasabah unik karena dataset tidak memuat kolom ID nasabah.

3.2 Eksplorasi dan Pembagian Data

Sel 6 Menghitung statistik numerik

```
# NIM: 202531075

df.describe().T.round(2)
```

	count	mean	std	min	25%	50%	75%	max
age	45211.0	40.94	10.62	18.0	33.0	39.0	48.0	95.0
balance	45211.0	1362.27	3044.77	-8019.0	72.0	448.0	1428.0	102127.0
day	45211.0	15.81	8.32	1.0	8.0	16.0	21.0	31.0
duration	45211.0	258.16	257.53	0.0	103.0	180.0	319.0	4918.0
campaign	45211.0	2.76	3.10	1.0	1.0	2.0	3.0	63.0
pdays	45211.0	40.20	100.13	-1.0	-1.0	-1.0	-1.0	871.0
previous	45211.0	0.58	2.30	0.0	0.0	0.0	0.0	275.0

Gambar 3.6 Statistik ringkas kolom numerik

Melalui describe().T.round(2), penulis memperoleh umur 18–95 tahun. Saldo memiliki rata-rata 1.362,27 euro, median 448 euro, minimum −8.019 euro, dan maksimum 102.127 euro. Selisih rata-rata dan median menjadi alasan memeriksa kemencengan sebaran. Pdays = -1 menandai belum pernah dihubungi pada kampanye sebelumnya.

Sel 7 Menghitung proporsi respons

```
# NIM: 202531075

jumlah = df["y"].value_counts()

pd.DataFrame({
    "jumlah": jumlah,
    "persentase": (jumlah / len(df) * 100).round(2)
})
```

y	jumlah	persentase
no	39922	88.3
yes	5289	11.7

Gambar 3.7 Jumlah dan persentase label deposito

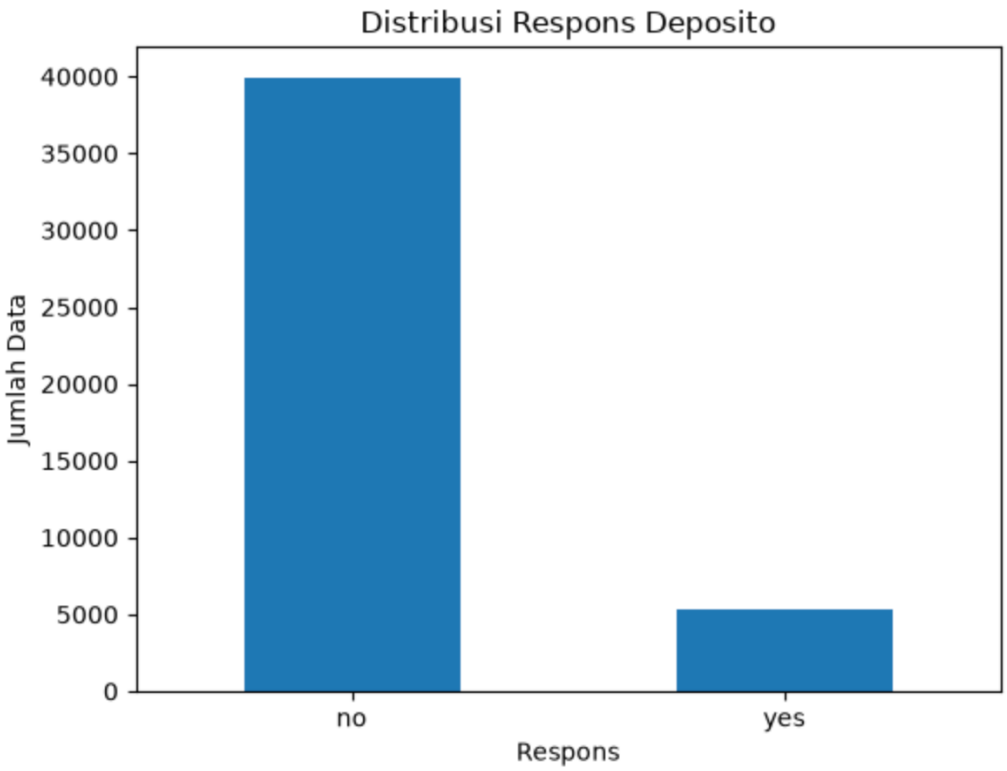
Value_counts() menghasilkan 39.922 no atau 88,30% dan 5.289 yes atau 11,70%. Label historis ini menunjukkan ketidakseimbangan kelas. Penulis perlu menilai pengenalan yes bersama akurasi keseluruhan.

Sel 8 Menampilkan distribusi respons

```
# NIM: 202531075

jumlah.plot(kind="bar", rot=0)

plt.title("Distribusi Respons Deposito")
plt.xlabel("Respons")
plt.ylabel("Jumlah Data")
plt.show()
```



Gambar 3.8 Distribusi respons langganan deposito

Penulis menggambar diagram batang dari jumlah respons pada sel 7. Batang no jauh lebih tinggi daripada yes, sesuai proporsi 88,30% dan 11,70%. Visual ini memperjelas bahwa kedua kelas tidak memiliki jumlah contoh yang seimbang.

Jika model sering mengeluarkan no, banyak prediksinya dapat benar karena kelas itu mendominasi data. Penulis tetap perlu memeriksa jumlah yes yang dikenali dan yang terlewat. Diagram ini memakai seluruh dataset sebagai bagian dari EDA awal; diagram tersebut bukan hasil prediksi model.

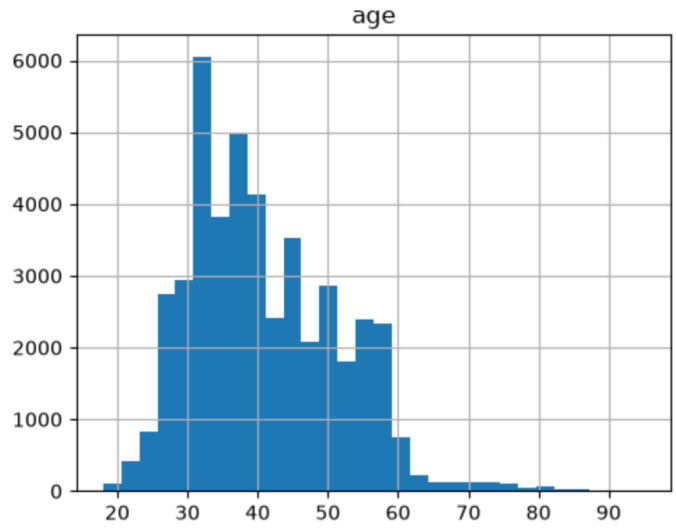
Sel 9 Menampilkan histogram umur dan saldo

```
# NIM: 202531075

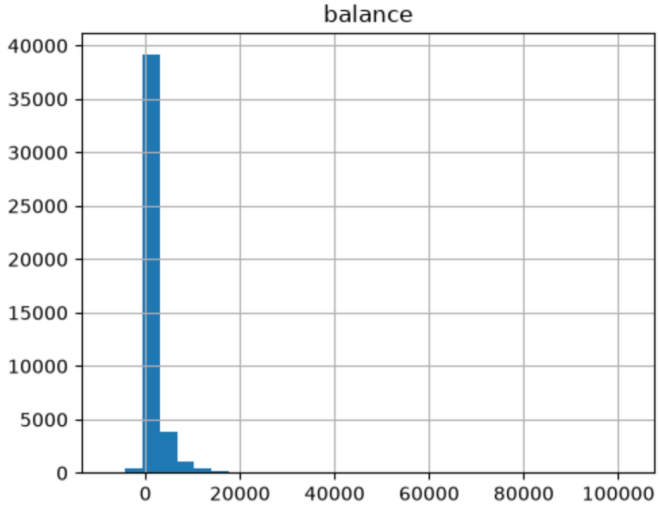
df[["age", "balance"]].hist(bins=30, figsize=(10, 4))

plt.tight_layout()
plt.show()
```

Gambar 3.9a Kode histogram dengan 30 interval



Gambar 3.9b Sebaran umur nasabah



Gambar 3.9c Sebaran saldo nasabah

Penulis membuat histogram dengan 30 interval. Umur banyak berada sekitar 30–60 tahun. Saldo terkumpul di bagian rendah dengan ekor panjang ke nilai besar. Penulis mempertahankan nilai ekstrem selama belum menemukan kesalahan pencatatan, lalu menelaah pengaruh galat besar melalui RMSE dan residual.

Sel 10 Membagi data latih dan data uji

```
# NIM: 202531075

latih, uji = train_test_split(
    df,
    test_size=0.2,
    random_state=42,
    stratify=df["y"]
)

pd.DataFrame({
    "jumlah_data": [len(latih), len(uji)]
}, index=["Latih", "Uji"])
```

	jumlah_data
Latih	36168
Uji	9043

Gambar 3.10 Pembagian data dengan rasio 80 banding 20

Penulis memakai train_test_split dengan test_size=0.2. Data latih berjumlah 36.168 baris dan data uji 9.043 baris. Nilai random_state=42 mempertahankan pembagian yang sama saat kode dijalankan ulang. Melalui stratify=df["y"], penulis menjaga proporsi yes dan no pada kedua bagian.

Data latih memberi contoh atribut beserta jawaban asli untuk mempelajari pola. Setelah pelatihan, model menerima atribut data uji untuk membuat perkiraan. Penulis kemudian membandingkan prediksi dengan jawaban data uji yang disimpan terpisah. Regresi Linear dan Naive Bayes memakai baris latih serta uji yang sama, tetapi targetnya berbeda.

3.3 Regresi Linear

Sel 11 Menyiapkan atribut regresi

```
# NIM: 202531075

X_latih_reg = latih.drop(columns=["balance", "y", "duration"])
X_uji_reg = uji.drop(columns=["balance", "y", "duration"])

y_latih_reg = latih["balance"]
y_uji_reg = uji["balance"]

X_latih_reg = pd.get_dummies(X_latih_reg, drop_first=True, dtype=int)
X_uji_reg = pd.get_dummies(X_uji_reg, dtype=int)

X_uji_reg = X_uji_reg.reindex(
    columns=X_latih_reg.columns,
    fill_value=0
)

X_latih_reg.head()
```

Gambar 3.11a Pemilihan target dan pengkodean dummy

	age	day	campaign	pdays	previous	poutcome_other	poutcome_success	poutcome_unknown
24001	36	29	2	-1	0	0	0	1
43409	24	5	4	185	7	0	0	0
20669	44	12	4	-1	0	0	0	1
18810	48	31	11	-1	0	0	0	1
23130	38	26	10	-1	0	0	0	1

Gambar 3.11b Cuplikan kolom awal dan akhir hasil pengkodean

Penulis memilih balance sebagai target dan mengeluarkan balance, y, serta duration dari masukan. Tersisa 14 atribut asal. Melalui get_dummies(), penulis mengubah kategori menjadi indikator 0 atau 1, sehingga data latih memiliki 40 kolom numerik dan dummy.

Drop_first=True memilih kategori acuan pada data latih. Penulis membuat dummy lengkap pada data uji, lalu memakai reindex untuk menyamakan kolom dengan data latih dan mengisi kolom yang tidak tersedia dengan 0.

Sel 12 Melatih regresi dan membuat prediksi

```
# NIM: 202531075

model_reg = LinearRegression()
model_reg.fit(X_latih_reg, y_latih_reg)

prediksi_reg = model_reg.predict(X_uji_reg)

hasil_reg = pd.DataFrame({
    "saldo_asli": y_uji_reg,
    "saldo_prediksi": prediksi_reg
})

hasil_reg.head(10).round(2)
```

	saldo_asli	saldo_prediksi
1392	640	360.62
7518	378	1171.69
12007	356	1104.18
5536	655	844.26
29816	1921	950.71
18275	1138	1328.01
8543	2589	2116.86
43965	109	2203.58
28083	1803	428.66
25787	2279	2038.30

Gambar 3.12 Pelatihan Regresi Linear dan contoh prediksi

Penulis membuat objek LinearRegression, lalu memanggil fit memakai atribut dan saldo data latih. Setelah koefisien terbentuk, predict menghasilkan perkiraan saldo data uji. Tabel hasil_reg memasangkan saldo_asli dan saldo_prediksi untuk baris yang sama.

Pada indeks 1392, saldo asli 640 euro dan prediksi 360,62 euro. Pada indeks 43965, saldo asli 109 euro dan prediksi 2.203,58 euro. Contoh ini memperlihatkan adanya perkiraan yang lebih rendah dan lebih tinggi dari nilai sebenarnya. Penulis memakai seluruh 9.043 prediksi untuk evaluasi, bukan hanya sepuluh baris yang tampil.

Sel 13 Mengukur galat regresi

```
# NIM: 202531075

mae = mean_absolute_error(y_uji_reg, prediksi_reg)
rmse = np.sqrt(mean_squared_error(y_uji_reg, prediksi_reg))
r2 = r2_score(y_uji_reg, prediksi_reg)

pd.DataFrame({
    "MAE": [mae],
    "RMSE": [rmse],
    "R2": [r2]
}).round(4)
```

	MAE	RMSE	R2
0	1486.6654	2868.3408	0.0531

Gambar 3.13 MAE RMSE dan R kuadrat pada data uji

Tabel 3.1 Evaluasi prediksi saldo

Ukuran	Hasil
MAE	1.486,6654 euro
RMSE	2.868,3408 euro
R^2	0,0531

Penulis menghitung MAE sebagai rata-rata besar selisih saldo asli dan prediksi. Nilai 1.486,6654 euro berarti model meleset sebesar itu secara rata-rata dalam ukuran absolut. RMSE sebesar 2.868,3408 euro lebih besar daripada MAE; beberapa kesalahan besar memberi pengaruh kuat pada ukuran kuadrat galat.

Nilai R^2 sebesar 0,0531 menunjukkan kemampuan penjelasan variasi saldo yang rendah pada data uji. Dibanding jumlah kuadrat penyimpangan dari rata-rata saldo data uji, jumlah galat kuadrat model berkurang sekitar 5,31%. Angka tersebut bukan akurasi 5,31%. Penulis menelaah grafik berikut untuk mengetahui bentuk kesalahannya.

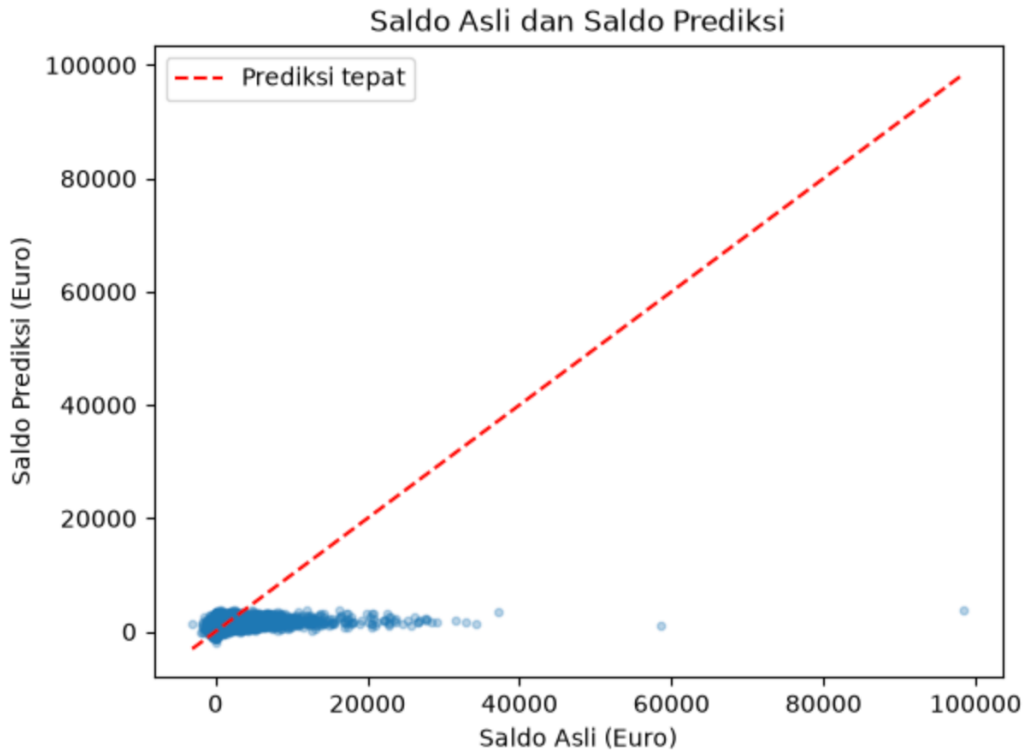
Sel 14 Membandingkan saldo asli dan prediksi

```
# NIM: 202531075

plt.scatter(y_uji_reg, prediksi_reg, alpha=0.3, s=10)

batas = [y_uji_reg.min(), y_uji_reg.max()]
plt.plot(batas, batas, "r--", label="Prediksi tepat")

plt.title("Saldo Asli dan Saldo Prediksi")
plt.xlabel("Saldo Asli (Euro)")
plt.ylabel("Saldo Prediksi (Euro)")
plt.legend()
plt.show()
```



Gambar 3.14 Saldo asli terhadap saldo prediksi

Penulis memakai scatter untuk memasangkan saldo asli pada sumbu mendatar dengan saldo prediksi pada sumbu tegak. Garis merah putus-putus menandai keadaan ketika kedua nilai sama. Titik yang jauh dari garis menunjukkan kesalahan prediksi yang besar.

Banyak prediksi terkumpul pada rentang sempit, sedangkan saldo aktual mencapai puluhan ribu euro. Untuk saldo aktual yang tinggi, model sering memberi perkiraan terlalu rendah. Pola ini sejalan dengan R^2 yang rendah dan RMSE yang besar. Penulis belum dapat menyimpulkan bahwa salah satu atribut tertentu menyebabkan kesalahan tersebut.

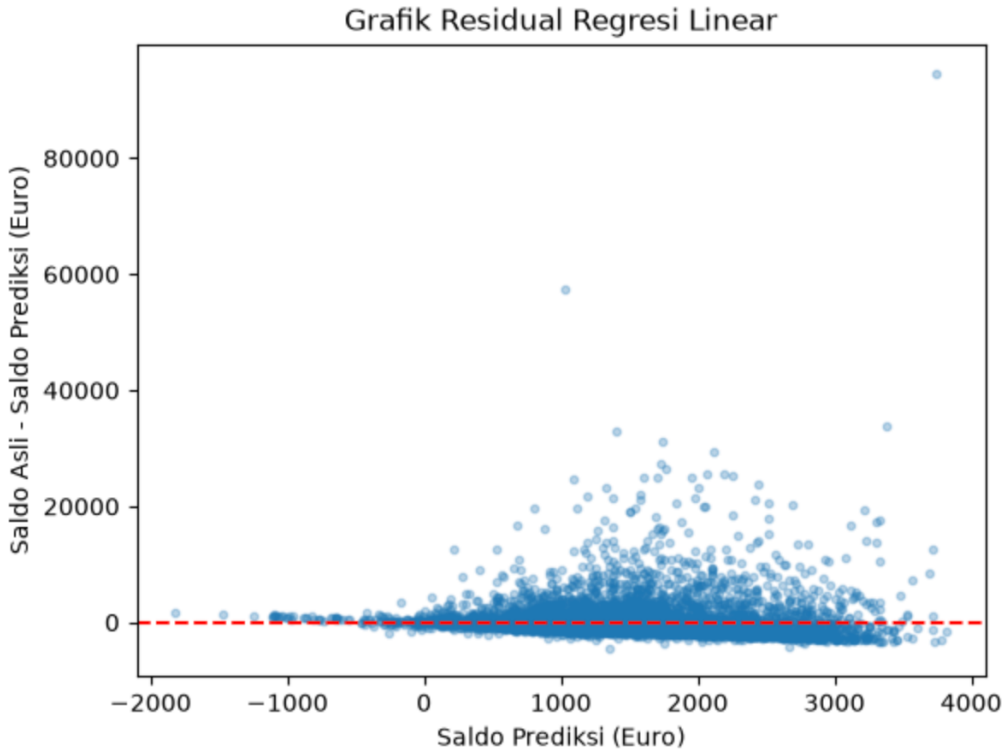
Sel 15 Memeriksa residual regresi

```
# NIM: 202531075

residual = y_uji_reg - prediksi_reg

plt.scatter(prediksi_reg, residual, alpha=0.3, s=10)
plt.axhline(0, color="red", linestyle="--")

plt.title("Grafik Residual Regresi Linear")
plt.xlabel("Saldo Prediksi (Euro)")
plt.ylabel("Saldo Asli - Saldo Prediksi (Euro)")
plt.show()
```



Gambar 3.15 Residual prediksi saldo

Penulis menghitung residual sebagai saldo asli dikurangi saldo prediksi. Residual positif berarti model memperkirakan saldo terlalu rendah; residual negatif berarti perkiraannya terlalu tinggi. Garis merah pada nol membantu penulis melihat arah kesalahan.

Pada grafik, sejumlah residual positif mencapai puluhan ribu euro dan beberapa titik berada di atas 90.000 euro. Sebaran kesalahan tidak terkumpul dekat nol dengan lebar yang seragam. Grafik ini memperkuat temuan bahwa model linear masih kesulitan mengikuti saldo tinggi. Pemeriksaan tersebut merupakan diagnosis visual dan belum menjadi pengujian formal seluruh asumsi regresi.

3.4 Naive Bayes

Sel 16 Menentukan atribut dan target klasifikasi

```
# NIM: 202531075

X_latih_nb = latih.drop(columns=["y", "duration"])
X_uji_nb = uji.drop(columns=["y", "duration"])

y_latih_nb = latih["y"]
y_uji_nb = uji["y"]

X_latih_nb.head()
```

Gambar 3.16a Pemilihan 15 atribut dan target y

	age	job	marital	education	default	balance	housing
24001	36	technician	divorced	secondary	no	861	no
43409	24	student	single	secondary	no	4126	no
20669	44	technician	single	secondary	no	244	yes
18810	48	unemployed	married	secondary	no	0	no
23130	38	technician	married	secondary	no	257	no

Gambar 3.16b Cuplikan atribut profil dan kondisi keuangan

loan	contact	day	month	campaign	pdays	previous	poutcome
no	telephone	29	aug	2	-1	0	unknown
no	cellular	5	apr	4	185	7	failure
no	cellular	12	aug	4	-1	0	unknown
no	telephone	31	jul	11	-1	0	unknown
no	cellular	26	aug	10	-1	0	unknown

Gambar 3.16c Kelanjutan atribut kontak dan kampanye

Penulis mengeluarkan y dan duration dari masukan, sehingga tersisa 15 atribut. Target klasifikasi adalah y dengan label no atau yes. Berbeda dari regresi, balance tetap menjadi atribut karena Naive Bayes memperkirakan status langganan deposito. Penulis menggunakan saldo asli yang tercatat, bukan hasil prediksi Regresi Linear.

Penulis mengeluarkan duration karena durasi baru lengkap setelah panggilan. Atribut lain masih memuat kontak terakhir dan jumlah kontak kampanye. Peneliti perlu memeriksa ketersediaannya sebelum menerapkan model untuk kontak pertama.

Sel 17 Membagi umur dan saldo menjadi interval

```
# NIM: 202531075

kolom_angka = ["age", "balance"]

pembagi = KBinsDiscretizer(
    n_bins=5,
    encode="ordinal",
    strategy="quantile",
    quantile_method="averaged_inverted_cdf"
)

angka_latih = pembagi.fit_transform(
    X_latih_nb[kolom_angka]
).astype(int)

angka_uji = pembagi.transform(
    X_uji_nb[kolom_angka]
).astype(int)

pd.DataFrame(angka_latih, columns=kolom_angka).head()
```

	age	balance
0	2	3
1	0	4
2	3	1
3	3	0
4	2	1

Gambar 3.17 Diskretisasi umur dan saldo menjadi lima interval

Penulis memilih age dan balance sebagai kolom_angka, lalu memakai KBinsDiscretizer dengan n_bins=5 dan strategy="quantile". Pembagian kuantil menempatkan pengamatan ke interval berdasarkan distribusi data latih. encode="ordinal" menghasilkan kode 0 sampai 4. Kode tersebut menunjukkan interval, bukan umur atau saldo aslinya.

Melalui fit_transform, penulis mempelajari batas interval dari data latih. Pada data uji, penulis hanya memanggil transform agar memakai batas yang sama. Output menampilkan lima contoh kode, misalnya baris pertama memiliki kelompok umur 2 dan kelompok saldo 3. Penulis tidak memberi nama remaja, dewasa, atau kaya pada kelompok tersebut.

Sel 18 Memberi kode kategori lainnya

```
# NIM: 202531075

kolom_kategori = X_latih_nb.columns.difference(kolom_angka)

pengkode = OrdinalEncoder(
    handle_unknown="use_encoded_value",
    unknown_value=-1
)

kategori_latih = pengkode.fit_transform(
    X_latih_nb[kolom_kategori].astype(str)
).astype(int) + 1

kategori_uji = pengkode.transform(
    X_uji_nb[kolom_kategori].astype(str)
).astype(int) + 1

pd.DataFrame(kategori_latih, columns=kolom_kategori).head()
```

Gambar 3.18a Pengkodean 13 kolom selain umur dan saldo

	campaign	contact	day	default	education	housing	job
0	12	2	22	1	2	1	10
1	34	1	27	1	2	1	9
2	34	1	4	1	2	2	10
3	3	2	25	1	2	1	11
4	2	1	19	1	2	1	10

Gambar 3.18b Cuplikan hasil kode kategori pada data latih

Penulis memilih 13 kolom lainnya melalui columns.difference(kolom_angka). Dengan astype(str), penulis memperlakukan tiap nilai sebagai kategori, termasuk day, campaign, pdays, dan previous yang semula berupa angka. OrdinalEncoder mempelajari daftar kategori per kolom dari data latih dan menerapkannya pada data uji.

Kategori yang belum dikenal memperoleh -1, lalu penambahan 1 mengubahnya menjadi 0. Kategori yang dikenal memakai kode mulai 1. Teks unknown yang sudah ada dalam data tetap menjadi kategori yang dikenal; teks itu berbeda dari kategori baru pada data uji. Pengkodean ini tidak menyatakan urutan pekerjaan atau tingkat keberhasilan kampanye.

Sel 19 Melatih Naive Bayes dan memprediksi respons

```
# NIM: 202531075

X_latih_nb_akhir = np.column_stack([angka_latih, kategori_latih])
X_uji_nb_akhir = np.column_stack([angka_uji, kategori_uji])

model_nb = CategoricalNB()
model_nb.fit(X_latih_nb_akhir, y_latih_nb)

prediksi_nb = model_nb.predict(X_uji_nb_akhir)

hasil_nb = pd.DataFrame({
    "respons_asli": y_uji_nb,
    "respons_prediksi": prediksi_nb
})

hasil_nb.head(10)
```

	respons_asli	respons_prediksi
1392	no	no
7518	no	no
12007	no	no
5536	no	no
29816	no	no
18275	no	no
8543	no	no
43965	yes	yes
28083	no	no
25787	no	no

Gambar 3.19 Pelatihan Categorical Naive Bayes dan contoh prediksi

Penulis menggabungkan dua kolom hasil diskretisasi dan 13 kolom hasil pengkodean menggunakan np.column_stack. Hasilnya adalah 15 atribut berkode dengan susunan yang sama pada data latih dan data uji. CategoricalNB memakai pengaturan bawaan, termasuk alpha=1 untuk penghalusan Laplace.

Pemanggilan fit menghitung pola kategori berdasarkan label data latih. Pemanggilan predict kemudian menghasilkan no atau yes untuk data uji. Sepuluh contoh pada tabel tampak sesuai dengan jawaban asli, termasuk yes pada indeks 43965. Kecocokan contoh tersebut belum mewakili seluruh data, sehingga penulis menghitung evaluasi lengkap pada sel 20.

Sel 20 Mengukur kinerja klasifikasi

```
# NIM: 202531075

akurasi = accuracy_score(y_uji_nb, prediksi_nb)

print("Akurasi:", round(akurasi * 100, 2), "%")
print(classification_report(y_uji_nb, prediksi_nb, zero_division=0))
```

```
Akurasi: 86.83 %
              precision    recall  f1-score   support

          no       0.92      0.93      0.93      7985
         yes       0.43      0.38      0.40      1058

    accuracy                           0.87      9043
   macro avg       0.67      0.66      0.66      9043
weighted avg       0.86      0.87      0.86      9043
```

Gambar 3.20 Akurasi dan classification report pada data uji

Penulis memperoleh akurasi 86,83% dari 9.043 data uji. Untuk kelas no, precision sebesar 0,92, recall 0,93, dan F1 0,93. Untuk kelas yes, precision sebesar 0,43, recall 0,38, dan F1 0,40. Nilai pada classification report dibulatkan menjadi dua angka desimal.

Precision yes menjelaskan ketepatan prediksi yang diberi label yes. Recall yes menjelaskan bagian dari seluruh nasabah berlangganan yang berhasil dikenali. Recall sekitar 0,38 berarti model mengenali sekitar 38 dari setiap 100 pengamatan yang sebenarnya yes. Jumlah kelas yes pada data uji adalah 1.058, sedangkan no berjumlah 7.985.

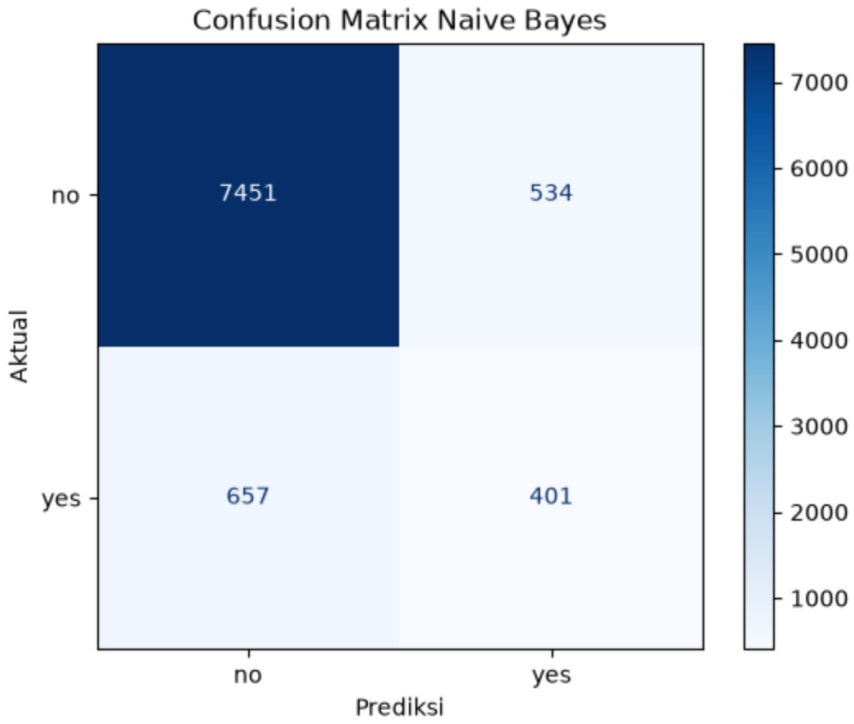
Macro average memberi bobot yang sama pada kedua kelas. Weighted average memberi bobot menurut jumlah anggota kelas, sehingga kelompok no yang lebih banyak memberi pengaruh lebih besar. Penulis memakai perbedaan metrik ini untuk menghindari kesimpulan keberhasilan yang hanya bertumpu pada akurasi. Confusion matrix berikut memperlihatkan jumlah kesalahan secara langsung.

Sel 21 Menampilkan confusion matrix

```
# NIM: 202531075

ConfusionMatrixDisplay.from_predictions(
    y_uji_nb,
    prediksi_nb,
    labels=["no", "yes"],
    cmap="Blues",
    values_format="d"
)

plt.title("Confusion Matrix Naive Bayes")
plt.xlabel("Prediksi")
plt.ylabel("Aktual")
plt.show()
```



Gambar 3.21 Confusion matrix dengan baris aktual dan kolom prediksi

Penulis menetapkan urutan label no lalu yes. Baris menunjukkan jawaban aktual dan kolom menunjukkan prediksi. Model mengenali 7.451 no dan 401 yes dengan benar. Sebanyak 534 no keliru menjadi yes, sedangkan 657 yes keliru menjadi no.

Jumlah prediksi benar adalah 7.852 dari 9.043, sesuai akurasi 86,83%. Recall yes adalah 401/1.058 atau 37,90%, sedangkan precision yes adalah 401/935 atau 42,89%. Untuk tujuan menemukan pelanggan yang berlangganan, 657 yes yang terlewat menjadi keterbatasan utama model pada percobaan ini.

3.5 Pembahasan Hasil dan Keterbatasan

Regresi Linear dan Naive Bayes menjawab dua pertanyaan berbeda. Regresi memperkirakan angka saldo, sedangkan klasifikasi memperkirakan status langganan deposito. Penulis tidak membandingkan R^2 dengan akurasi untuk memilih algoritma yang lebih baik karena kedua ukuran tersebut menilai target yang berbeda.

Tabel 3.2 Ringkasan hasil dua tugas prediksi

Tugas	Temuan utama
Prediksi saldo	MAE 1.486,6654 euro RMSE 2.868,3408 euro R^2 0,0531
Klasifikasi deposito	Akurasi 86,83% Recall yes 37,90% 401 yes dikenali dan 657 terlewat

Sebagai pembanding analitis, penulis menghitung akurasi jika seluruh data uji diberi label no. Dengan 7.985 no dari 9.043 data, hasilnya 88,30%. Angka ini berasal dari komposisi data uji, bukan dari keluaran model tambahan. Akurasi Naive Bayes lebih rendah sekitar 1,47 poin persentase, tetapi model berhasil mengenali 401 yes. Pembanding selalu no memiliki recall yes sebesar nol.

Pada regresi, prediksi terkumpul dalam rentang sempit dan sering terlalu rendah untuk saldo tinggi. Sebaran saldo yang menceng, nilai ekstrem, dan keterbatasan hubungan linear dapat berkaitan dengan pola galat. Percobaan ini belum menguji masing-masing dugaan tersebut secara terpisah. Pada Naive Bayes, ketidakseimbangan kelas serta pengkodean nilai diskret sebagai kategori dapat membatasi pengenalan yes.

Penulis memakai satu pembagian acak 80:20 dan melakukan EDA sebelum pembagian. Percobaan belum mencakup validasi silang, pencarian parameter, atau pengujian menurut waktu. Dataset tidak memiliki ID nasabah untuk memeriksa orang yang sama antarbagian. Pengujian ini menilai pengamatan tersisih dari kumpulan data yang sama, belum kampanye masa depan.

Penulis mengeluarkan duration, tetapi tetap memakai day, month, dan campaign yang merujuk kontak terakhir atau kampanye berjalan. Sebelum penggunaan operasional, peneliti perlu menetapkan waktu prediksi dan memeriksa atribut yang sudah tersedia pada saat itu.

BAB IV

PENUTUP

4.1 Kesimpulan

Penulis mengolah 45.211 catatan dengan 17 kolom tanpa nilai kosong standar atau duplikasi baris identik. Unknown tetap menjadi kategori. Respons no mencakup 88,30% dan yes 11,70%. Pembagian 80:20 menghasilkan 36.168 baris latih dan 9.043 baris uji.

Regresi Linear memprediksi balance dari 14 atribut asal atau 40 kolom dummy dan numerik. Penulis memperoleh MAE 1.486,6654 euro, RMSE 2.868,3408 euro, dan R^2 0,0531. Grafik memperlihatkan kesulitan mengikuti saldo tinggi, sehingga kemampuan prediksi saldo masih terbatas.

Categorical Naive Bayes memakai 15 atribut, dengan lima interval untuk umur dan saldo serta kode kategori bagi 13 kolom lain. Akurasi mencapai 86,83%, tetapi model hanya mengenali 401 dari 1.058 yes. Recall yes sebesar 37,90% menunjukkan banyak pelanggan berlangganan yang terlewat.

Prediksi selalu no memperoleh akurasi 88,30% dan recall yes nol. Penulis perlu membaca akurasi bersama metrik per kelas serta confusion matrix. Kesimpulan berlaku untuk pengolahan dan pembagian data pada percobaan ini; kedua algoritma mengerjakan target yang berbeda.

4.2 Saran

Penulis dapat menilai representasi fitur diskret dan parameter melalui validasi silang pada data latih. Untuk regresi, penulis perlu meninjau distribusi saldo. Untuk klasifikasi, penulis perlu memusatkan evaluasi pada kesalahan yes. Perbandingan dengan KNN atau Decision Tree harus memakai target dan rancangan pengujian yang setara.

Sebelum penerapan, peneliti perlu menetapkan waktu prediksi, memeriksa ketersediaan atribut, dan menguji urutan waktu bila hendak memperkirakan kampanye berikutnya. Data uji perlu tetap terpisah selama pemilihan pengolahan serta parameter.

DAFTAR PUSTAKA

[1] Lee Xuan Chian, Khai Wah Khaw, XinYing Chew, Alhamzah Alnoor, dan Wei Chien Ng. 2024. Bank Direct Marketing Campaign Success Prediction. Applied Mathematics and Computational Intelligence, 13(3), 95–114. DOI 10.58915/amci.v13i3.644.
Baca teks lengkap

[2] Roustaei, N. 2024. Application and interpretation of linear-regression analysis. Medical Hypothesis, Discovery & Innovation in Ophthalmology, 13(3), 151–159. DOI 10.51329/mehdiophthal1506.
Baca teks lengkap

[3] Gohari, K., Kazemnejad, A., Mohammadi, M., Eskandari, F., Saberi, S., Esmaieli, M., dan Sheidaei, A. 2023. A Bayesian latent class extension of naive Bayesian classifier and its application to the classification of gastric cancer patients. BMC Medical Research Methodology, 23, artikel 190. DOI 10.1186/s12874-023-02013-4.
Baca teks lengkap

[4] Kapoor, S., dan Narayanan, A. 2023. Leakage and the reproducibility crisis in machine-learning-based science. Patterns, 4(9), artikel 100804. DOI 10.1016/j.patter.2023.100804.
Baca teks lengkap

[5] Chicco, D., dan Jurman, G. 2022. The ABC recommendations for validation of supervised machine learning results in biomedical sciences. Frontiers in Big Data, 5, artikel 979465. DOI 10.3389/fdata.2022.979465.
Baca teks lengkap

[6] Izma, F., dan Firmansyah, H. 2026. Penerapan Algoritma Naive Bayes untuk Memprediksi Keputusan Berlangganan Deposito Berjangka pada Kampanye Pemasaran Langsung. Jurnal Dinamika Informatika, 15(1), 140–148. DOI 10.31316/jdi.v15i1.427.
Baca teks lengkap